

Hermes AgentOS

生产级多智能体操作系统

不只是把多个 Agent 串起来，而是给它们一套可校验、可自愈、可观测的运行时。
让多智能体协作从「跑得通的 Demo」变成「敢上生产的系统」。

Skill 化架构

DAG 并行调度

输出防火墙

四级自愈回滚

经验记忆

AI 圆桌

7

Skill Agents

18

事件契约

4

级自愈策略

8

阶段 Trace

多智能体离生产，还差三道坎

模型能力已经够用，缺的是把它们「管起来」的工程底座

01

输出不可信

LLM 幻觉直接流入下游节点，错误逐级放大；最后一公里只能靠人肉复核，规模化无从谈起。

02

失败不可恢复

一次超时、限流或格式漂移就让整条链路崩溃，只能整体重跑，既贵又慢，没有恢复策略。

03

过程不可观测

黑盒执行：卡在哪一步、烧了多少 Token、成本花在哪都说不清，问题无法定位到阶段。

缺的不是更聪明的 **Agent**，而是一套能治理它们的 **OS** —— 校验、自愈、观测，必须做进运行时。

Hermes AgentOS：把治理能力做进运行时

Agent 只负责「想」，可靠性由 OS 统一负责

执行层 EXECUTION	Planner 任务拆解 · DAG 并行调度器 · 7 个 Skill Agent
治理层 GOVERNANCE	Validator 输出防火墙 · Rollback 四级自愈 · Experience Memory
协作层 COLLABORATION	Moderator 主持的 AI 圆桌 · 多轮辩论 · 共识合成与收敛
观测层 OBSERVABILITY	Trace 8 阶段全链路 · Snapshot 快照 · Token / Cost 实时统计

一句话：*Skill* 负责能力，*Runtime* 负责可靠性 —— 新增一个 *Agent*，不用碰任何调度、重试、观测代码。

端到端类型安全的三段式架构

前端 · BFF 桥接 · AgentOS 内核，全链路共享一份事件契约



@hermes/shared · 18 个类型安全事件契约



所有 Agent 通过同一条事件总线上报状态：前端看到的每一次流式输出、每一个节点变色、每一笔 Token 消耗，都来自真实执行流，没有一处是前端伪造的动画。

声明式 Skill：新增 Agent 不写调度代码

每个 Agent 只声明「它会什么」，其余全部由 Runtime 托管

```
packages/server/src/agents/analyst/
```

└ skill.json	能力声明 / 版本 / 复杂度
└ prompt.ts	结构化 Prompt 构建
└ schema.ts	输出数据结构定义
└ validator.ts	输出 Schema 校验
└ tools.ts	工具与数据源绑定

Runtime 统一托管

- Trace 生命周期8 个阶段自动埋点上报
- Snapshot 快照输入 / 输出双向落盘留痕
- 重试与退避最多 5 次尝试，2s 递增退避
- 错误分类DATA / MODEL / TOOL / POLICY
- 模型选择与回写按经验记忆选模型并回写成败

接入一个新 Agent = 5 个声明式文件 + 0 行调度代码。能力可插拔，可靠性不重复建设。

拓扑分层 + 同层并行的任务调度器

Planner 拆解依赖，Scheduler 用 Kahn 算法分层，能并行的绝不串行



调度器不理解业务，只理解依赖

Planner 输出的 DAG 是纯数据结构，Scheduler 只做「谁的依赖满足了就派谁上」。
换业务场景不需要改调度代码 —— 换一份任务图就行。

01 Kahn 拓扑排序

按依赖关系自动分层，无需手写编排顺序

02 同层并行执行

互不依赖的子任务同时开跑，压缩端到端耗时

03 上下文自动注入

上游产出裁剪后注入下游 Prompt，带角色标签

04 死锁检测与安全阀

环依赖立即上报，maxRounds 防止无限循环

Validator 输出防火墙：不合格就别想过去

每一个 Agent 的产出都要过一道独立质检，四维打分，一票否决

ACCURACY

准确性

事实与数据是否站得住

COMPLETENESS

完整性

任务要求是否全部覆盖

SAFETY


安全性

是否越界或含有害内容

FORMAT

格式

是否符合下游 Schema



- **failCodes** 对齐错误分类
- 最多 5 轮拦截—修复循环
- 圆桌共识同样受管

校验失败码与 DATA / MODEL / TOOL / POLICY 一一对应，恢复策略可直接消费

每次拦截都会触发一次恢复尝试，反复不过才升级为人工工单

多智能体讨论出的最终方案，也必须通过防火墙才允许发布

Rollback 自愈引擎：四级恢复阶梯


失败不是终点，而是恢复流程的入口 —— 由 Rollback Agent 决策，确定性兜底



错误分类覆盖 DATA_ERROR / MODEL_ERROR / TOOL_ERROR / POLICY_ERROR 四类，不同错误走不同恢复路径。

经验记忆：系统跑得越多，选得越准

把每一次成败都变成下一次的决策依据 —— 一个会自我进化的飞轮



`pickModel()`

正向选型

按角色 × 模型 × 任务类型的历史成功率挑选执行模型

`pickFallback()`

回退排序

回滚时把最可能成功的备选模型排到最前，减少无效重试

大多数框架的模型配置是静态的 —— 写死在配置文件里，好不好用全凭人工经验。


Hermes 让运行数据自己说话：跑得越久，模型路由与恢复顺序越贴合真实表现。

AI 圆桌：让智能体互相「吵」出更优解

不是串行流水线，而是有主持人、有立场、有收敛机制的多轮辩论



STANCE TAGS



收敛机制：最多 3 轮，主持人强制产出结论

多智能体讨论最怕发散不收口。Moderator 承担议程控制与最终合成，输出「共识 / 分歧 / 执行任务 / 风险项」四段式结构化结果。


VISUALIZATION

3D 像素圆桌

- **Three.js + CSS2D 渲染**
七个席位环绕圆桌，可自由旋转视角
- **思考态动画**
头部摆动 / 光环脉冲，实时反映谁在推理
- **发言气泡**
持久展示每位智能体的观点摘要
- **结论定格**
共识达成后统一呈现最终方案

全链路 Trace：每一步都留痕、可回放

从上下文构建到模型调用再到输出校验，8 个阶段逐一埋点



每个阶段都带 模型 / Token / 成本 / 耗时 / 尝试次数，点击 DAG 节点即可展开完整执行时间线。

SNAPSHOT

快照留痕

每次执行的输入与输出双向落盘，既是回放素材，也是快照回滚的恢复源。

TOKEN / COST

成本透明

Token 按 Agent 归集、成本按模型归集，实时汇总到统计接口。

DASHBOARD

运行看板

总运行数、成功率、Token 分布与智能体表现对比，一屏掌握全局。

可观测不是事后补的日志——它是回滚决策的输入。没有 Trace 与 Snapshot，就没有自动恢复。

一次真实的自愈闭环，全程无人介入

这是把前面所有能力串起来之后，系统实际发生的事



同样的失败，在普通编排框架里是一条报错日志；在 **Hermes** 里，是一次被记录、被决策、被恢复的事件。

演示场景：新能源行业战略分析周报

内置完整数据集与三条演示指令，离线也能跑通全链路



TASK	战略分析周报	三条主线为框架，采集 → 调研 → 建议 → 成稿，要求区分事实与推断
ROUNDTABLE	哪条主线最值得优先配置	四个智能体各司其职圆桌辩论，结论必须通过质检
TASK	分阶段配置策略评估	基于预置数据，评估「先储能、后光伏、再新能源车」是否成立

MOCK_LLM = 1

零依赖演示

没有 API Key 也能跑通：拆解、并行、拦截、自愈、圆桌与 Trace 全部真实执行，只有模型响应来自内置数据集。

技术栈与工程质量

不是一次性 Demo 代码 —— 按可维护、可验证的工程标准建设

技术栈

运行时	Node.js 20 · TypeScript · pnpm Monorepo
服务端	Koa · Socket.IO · OpenAI 兼容网关
前端	Vue 3 · Naive UI · Next.js 16 / React 19
可视化	Three.js 3D 圆桌 · React Flow DAG 画布
共享层	@hermes/shared 端到端类型定义

工程质量

端到端类型安全	前后端共享 18 个事件契约，改协议即刻编译报错
逻辑自测脚本	600+ 行断言覆盖拆解、调度、回滚、圆桌与统计链路
Mock 优先设计	无网络无密钥即可完整回归，不依赖外部服务
韧性默认开启	5 次尝试 + 递增退避 + 四类错误分类兜底
状态可持久化	快照与经验记忆落盘，重启不丢历史

把重试、校验、回滚、观测下沉到运行时，业务代码才敢薄 —— 这是能长期演进的前提。

和通用编排框架的关键差别

同样是多智能体，差别不在能不能跑通，而在跑不通时会发生什么

维度	通用编排框架的常见做法	HERMESAGENTOS
输出质量	依赖 Prompt 约束与人工复核	Schema + 四维评分防火墙，不合格直接拦截
失败处理	重试若干次，失败即抛错	四级自愈阶梯，最终降级为带建议的人工工单
模型选择	静态配置，改模型要改代码	经验记忆按历史成功率动态选型与排序回退
可观测性	打印日志，事后翻查	8 阶段 Trace + 双向快照 + Token / 成本归集
协作形态	链式调用或主从分发	有主持人、有立场、能收敛的圆桌辩论

我们不打算取代编排框架——我们补的是它们普遍留白的那一层：治理。

从黑客松原型，到可托管的 Agent 基础设施

NEXT

LLM 规划器

把规则式 Planner 升级为模型驱动的动态任务图生成

THEN

Skill 市场与灰度

基于 skill.json 版本做 A/B 与自动回滚，能力可分发

LATER

成本护栏与多租户

预算上限、配额隔离与团队级用量治理

Hermes AgentOS

让多智能体，敢上生产。

感谢观看 — 欢迎现场提问与实机演示

THANK YOU

liufelix2004 / hermes-agentos