

Hermes AgentOS

让 AI 开一场圆桌会议

多个智能体带着不同立场同台辩论，由主持人收敛成一份经过质检的可执行方案——而不是让单个模型独自给答案。

7

个智能体同席

3

轮辩论收敛

4

维出口质检

0

人工介入

圆桌辩论

输出防火墙

四级自愈

经验记忆

全链路 Trace



一个 Agent 的答案，没人敢直接用

模型能力已经够用，缺的是一套让结论「可被质疑、可被推翻、可被验证」的机制

01

单点视角

一个模型一次推理就给结论，缺少对立面。它的盲区就是整个系统的盲区，没有任何环节会提出反对意见。

02

无从追责

答案是怎么来的、哪一步的判断出了问题、依据是什么，全都藏在一次调用里，出错后无法定位到具体环节。

03

不敢落地

没有质检闸门，输出好坏只能靠人肉复核。最后一公里始终卡在「要不要相信它」，规模化无从谈起。

真正缺的，是让多个智能体先把问题「吵清楚」的场

对抗产生盲区覆盖，收敛产生可执行结论，质检产生可信度。

AI 圆桌

让分歧先发生在系统内部

- 同席不同责

七个智能体各自带着专业视角入场，数据、调研、分析、撰写、质检互相独立，天然形成交叉验证。

- 有立场地发言

每次发言都带明确立场标签：提案、质疑、补充、收敛 —— 系统鼓励反对，而不是附和。

- 主持人负责收口

Moderator 控制议程与轮次，强制在三轮内产出结论，杜绝多智能体讨论常见的发散不收尾。



四个阶段，把一场讨论变成一次交付

Moderator 全程掌舵：先定标准，再收集观点，然后合成方案，最后交给质检

01 GOAL

目标确认

主持人开场即锁定议题、成功标准与轮次上限，讨论有边界才收得住。

02 DEBATE

多轮发言

参与者按序表态，第二轮起被指派质疑或补充，强制产生对立面。

03 SYNTHESIS

共识合成

主持人汇总共识与分歧，产出最终方案、执行任务与风险清单。

04 FIREWALL

出口质检

共识必须通过 Validator 四维评分，不合格则回炉重修而非直接发布。

收敛保证

轮次上限硬编码为 3 —— 讨论可以激烈，但必须在第三轮结束前交出结论。主持人不是参与者，它只负责让会议开出结果。

谁上桌，以及他们被允许说什么

角色决定视角，立场标签决定发言的性质 —— 两者共同保证讨论不会变成附和

	主持人	MODERATOR	定标准、控轮次、做最终合成
	研究员	RESEARCH	行业动态、政策与供需研判
	分析师	ANALYST	指标解读、洞察与分阶段建议
	撰稿员	WRITER	结构化表达与成稿输出
	数据员	DATA	数据采集、口径与置信度标注
	验证员	VALIDATOR	出口质检，四维评分一票否决
	回滚员	ROLLBACK	失败接管，决策恢复策略

STANCE TAGS

发言必须表态

-  propose 提案
-  challenge 质疑
-  supplement 补充
-  moderate 主持
-  synthesize 收敛

第二轮起强制分派对立立场

同一批智能体在第二轮被轮流指派为质疑方与补充方，确保每个提案都至少被正面挑战过一次。

三轮辩论：从各说各话到互相咬合

同一个议题在三轮里被反复挤压，观点的质量在对抗中提升



收敛：一份四段式的结构化交付

主持人不复述讨论，而是把讨论压缩成能直接派工的结果



讨论的价值不在于热闹，而在于最后能派工。

执行任务清单可以直接喂回任务流水线，由 DAG 调度器接着跑。

共识也要过闸：出口防火墙

圆桌讨论出的最终方案没有豁免权——不过质检，就不允许发布



拦截不是终点：每次不通过都会触发一轮恢复，最多五轮仍不过才升级为人工工单。
这条闸门同样作用于每一个 Agent 的中间产出，圆桌只是它守住的最后一道。

看得见的圆桌：3D 实时舞台

讨论过程不是日志，而是一个可以现场旋转观看的三维场景

为什么值得做成 3D

多智能体最难被感知的是「同时性」——谁在等、谁在想、谁在反对。
平铺的聊天流表达不了这件事，一张桌子可以。

- **Three.js + CSS2D**
七个席位环绕圆桌，可自由旋转与缩放视角
- **思考态动画**
头部摆动与光环脉冲，实时反映谁正在推理
- **持久发言气泡**
每位智能体的观点摘要停留在座位上方
- **结论定格**
共识达成后场景统一切换为最终方案展示



圆桌敢用，是因为下面有一整套底座

一场会议开得好不好，取决于参会者靠不靠谱、失败能不能兜住、过程能不能查

执行层

EXECUTION

Planner 任务拆解 · DAG 并行调度 · 7 个声明式 Skill Agent

治理层

GOVERNANCE

Validator 输出防火墙 · Rollback 四级自愈 · Experience Memory

协作层

COLLABORATION

Moderator 主持的 AI 圆桌 · 立场化多轮辩论 · 共识合成

← 本次重点

观测层

OBSERVABILITY

Trace 8 阶段全链路 · Snapshot 快照 · Token / Cost 实时归集

接下来三页快速交代底座：能力怎么装、失败怎么救、过程怎么查。

能力怎么装：声明式 Skill + DAG 调度

Agent 只声明「它会什么」，调度、重试、观测由运行时统一托管

agents/analyst/

└ skill.json	能力声明 / 版本 / 复杂度
└ prompt.ts	结构化 Prompt 构建
└ schema.ts	输出数据结构定义
└ validator.ts	输出 Schema 校验
└ tools.ts	工具与数据源绑定

新增一个 Agent = 5 个声明式文件 + 0 行调度代码

DAG SCHEDULER

拓扑分层，能并行的绝不串行




- Kahn 拓扑排序自动分层，无需手写编排顺序
- 同层任务并行执行，上游产出自动注入下游上下文
- 环依赖立即上报，安全阀防止无限循环


调度器不理解业务，只理解依赖 —— 换场景只需换一份任务图，不改调度代码。

失败怎么救：四级自愈 + 经验记忆

失败不是终点，而是恢复流程的入口；每一次成败都会改变下一次的选择




错误分类覆盖 DATA / MODEL / TOOL / POLICY 四类，不同错误走不同恢复路径。



过程怎么查：8 阶段全链路留痕

从上下文构建到模型调用再到输出校验，每一步都带模型、Token、成本与耗时



SNAPSHOT

快照留痕

每次执行的输入与输出双向落盘，既是回放素材，也是快照回滚的恢复源。

TOKEN / COST

成本透明

Token 按智能体归集、成本按模型归集，实时汇总到统计接口。

DASHBOARD

运行看板

总运行数、成功率、Token 分布与智能体表现对比，一屏掌握全局。

可观测不是事后补的日志 —— 它是回滚决策的输入。没有 Trace 与 Snapshot，就没有自动恢复。

现场演示：新能源主线之争

一个真实会有分歧的议题 —— 储能、光伏、新能源车，哪条最值得优先配置

42.6 GWh

储能上半年新增装机

+58.3 %

储能装机同比

128 GW

光伏上半年新增装机

54.7 %

新能源车渗透率

ROUNDTABLE TOPIC

储能、光伏、新能源车三条主线中，当前哪条最值得优先配置？要求数据员给出装机与渗透率、研究员分析供需与政策、分析师给出分阶段建议、撰稿员汇总为可执行方案，最后必须通过质检。

MOCK_LLM = 1

零依赖演示

没有 API Key 也能跑通整场圆桌：辩论、收敛、质检、回滚与 Trace 全部真实执行，只有模型响应来自内置数据集。

演示数据为仓库内置模拟数据集，字段结构与真实数据源一致。

和常见多智能体方案的关键差别

差别不在能不能跑通，而在结论从哪来、跑不通时会发生什么

维度	常见做法	HERMES AGENTOS
协作形态	链式调用或主从分发，角色之间不交锋	有主持人、有立场、能收敛的圆桌辩论
结论来源	单个模型一次推理的输出	多视角对抗后被保留下来的部分
输出质量	依赖 Prompt 约束与人工复核	四维评分防火墙，不合格直接拦截
失败处理	重试若干次，失败即抛错	四级自愈阶梯，最终降级为带建议的工单
模型选择	静态配置，改模型要改代码	经验记忆按历史成功率动态选型

我们不打算取代编排框架 —— 我们补的是它们普遍留白的那两层：对抗与治理。

从一场会议，到一套会议制度

NEXT

动态议程

主持人根据议题复杂度自行决定轮次与参会角色

THEN

Skill 市场

基于版本做能力灰度与自动回滚，圆桌可自由组队

LATER

成本护栏

预算上限与配额隔离，让长辩论也花得可控

Hermes AgentOS

让 AI 开一场圆桌会议

感谢观看 — 欢迎现场提问与实机演示

